

VICTOR GOUDAL

Ingénieur IA & HPC

Contact

07 77 44 83 53

vi.goudal@gmail.com

Marseille, France

victorgoudal07

victrolles

portfolio

Compétences IA

PyTorch · Transformers
DDP · FSDP · DeepSpeed
Fine-tuning · Quantification
CNN · RNN · RL

HPC & GPU

Slurm · CUDA · NCCL
Multi-GPU / multinœud
JUBE · Nsight
PyTorch Profiler

Outils

Python · Linux · Bash
Docker · Apptainer
Kubernetes · Git
Jupyter · W&B

Langues

Français : maternel
Anglais : C1+ (9 mois aux États-Unis)

Loisirs

Badminton · Cyclisme · Jeux de société · Gastronomie

Expériences professionnelles

Research Analyst Intern *octobre 2025 – mai 2026*

Flatiron Institute (New York, États-Unis)

- **Supercalculateur :** Rusty (A100 → B300 + MI350), Slurm
- **Entraînement distribué :** PyTorch DDP, FSDP/FSDP2
- **Benchmarking HPC :** GPU NVIDIA, multinœud, JUBE, Slurm, Apptainer
- **Optimisation IA :** profilage GPU, inférence quantifiée, performances
- **Support scientifique :** tutoriel FSDP/FSDP2 destiné aux chercheurs
- **Déploiement IA :** plateforme d'inférence IA, Docker, Kubernetes

Stagiaire Assistant Ingénieur *août 2023 – janvier 2024*

IDRIS (Orsay, 91)

- **Supercalculateur :** Jean Zay, Slurm
- **Benchmarks :**
  - Méthodes de parallélisation : DDP, FSDP, DeepSpeed
  - Précision mixte : AMP
  - Inférence : Deepspeed Inference, vLLM
- **Optimisation IA :** profilage, parallélisation, data loading
- **Projet PIE :** benchmarks + optimisation IA/HPC

Formation

Diplôme d'ingénieur IA / Vision artificielle *2020 – 2026*

Université de Technlogie de Belfort-Montbéliard (France)

Cours suivis :

- Linux (Ubuntu)
- Parallel Computing (C++ / Python / DL)
- IA (Prolog / Python)

Master en IA *2024 – 2025*

Université du Québec à Chicoutimi (Canada)

Cours suivis :

- Fondamentaux du ML / DL : Méthodes d'apprentissage, fonctions de perte, rétropropagation, pré-traitement des données
- Vision artificielle : CNN, data augmentation, segmentation
- Cloud computing : Docker, Kubernetes

Projets :

- Chatbot sur Kubernetes
- Chatbot avec RAG (Hackathon - 1000$ remporté)
- Apprentissage par renforcement (DQN, SAC)
- Etude de Torch Compiler

Certifications

- Fundamentals of Accelerated Computing with CUDA Python – **Nvidia**
- Getting Started with Deep Learning – **Nvidia**
- MPI – **IDRIS**
- DLO-JZ – **IDRIS**

Travaux scientifiques & projets

- Présentation sur l'inférence quantifiée à DP2E-AI (Mines Paris – PSL)
- Article rédigé sur l'inférence quantifiée
- 2 rapports de recherche :
  - NLP et développement de benchmarks
  - Projet PIE et entrainement d'une IA
- Nombreux projets d'apprentissage par renforcement (Github)